

LLM 평가 보고서: Self-host 파인튜닝 vs Commercial Small

메이플스토리 + 이터널리턴 도메인 · Closed-book vs Open-book(RAG)
작성: 양건호 (2026-05-08)

총 응답: 480건 / 모델: 4종 / 질문: 60개 / 실측 비용: \$0.289

모델	클래스	호스팅
Gemma 4 E4B + LoRA	self-host 파인튜닝	Modal A10G
EXAONE 3.5 2.4B	국내 base small (LG)	Apple Silicon Metal
Claude Haiku 4.5	상용 small (Anthropic)	Anthropic API
GPT-5.4 mini	상용 small (OpenAI)	OpenAI API

데이터셋

메이플스토리: 30개 (직업 8 / 보스 8 / 시스템 8 / 패치 6) — 나무위키 evidence-grounded
이터널리턴 11.0: 30개 (실험체 12 / 아이템 8 / 시스템 6 / 신규 4) — 모든 모델 학습 컷오프 이후

평가 모드

Closed-book: 모델 자체 지식만으로 답변
Open-book (RAG): 정답 근거(source_excerpt)를 system prompt로 주입 후 답변

채점: GPT-4o-mini judge (correctness 1-5 / hallucination y-n / 키워드 자동 매칭)

RAG 효과: 정답률 상승 + 환각률 감소




Figure 1. Closed-book 조건에서 모델별 환각률 격차는 최대 47%p에 달했으나, open-book RAG context 주입 시 4 모델이 모두 한 자릿수로 수렴했다. Gemma4+LoRA는 closed-book에서 환각률 28%로 가장 정직한 응답 분포를 보였으며, 본 평가 결과를 근거로 라이브 붓 데비&마를렌의 채택 모델로 선정됐다. (a, b) 평균 정답률(1-5) — closed 1.81 → open 4.63 (+2.82점), 두 도메인 공통. (c, d) 환각률(%) — RAG 주입 시 모델 간 차이가 사실상 소멸한다.

운영 비용·지연 트레이드오프




Figure 2. 운영 환경에서 모델 선택은 정답률만으로 결정되지 않는다. 응답 지연은 4 모델 사이에서 중앙값 기준 0.7s ~ 5.6s, 호출당 비용은 수 자릿수 격차를 보였다. 정답률 최상위인 GPT-5.4 mini는 평균 비용 \$0.0004/call로 corr 4.80/5에 도달 — 운영 채택 후보. (a) 응답 시간 분포 — EXAONE 3.5가 가장 빠르고(0.7s), Gemma4+LoRA가 가장 느리다(5.6s). (b, c) 호출당 평균 비용(log scale) vs 정답률 산점도. RAG context 주입은 입력 토큰 증가로 비용 축을 함께 끌어올린다.

카테고리별 정답률 heatmap



Figure 3. 도메인의 학습 노출 수준이 모델 간 카테고리별 정답률 분포를 결정한다. 부분 학습 도메인일수록 closed-book에서 카테고리 비대칭 환각이 누적되고, 미학습 신규 도메인일수록 RAG 의존도가 높아진다. RAG 이득이 가장 큰 카테고리는 er · 신규 (+3.75점). (a, b) MapleStory — closed-book에서 직업·보스 카테고리에 약점이 누적되며 모델 간 격차가 가장 크다. (c, d) Eternal Return 11.0(컷오프 이후 패치) — closed에서는 4 모델이 균일하게 낮으나 RAG 주입 시 격차 없이 함께 상승한다. 색이 빨강일수록 약점, 녹색일수록 강점(1 = 오답, 5 = 정답).

Multi-turn 평가 (10 dialogues × 4 models = 40 응답)




Figure 4. 동일 시나리오 10건을 멀티턴으로 진행했을 때, 모델 간 정답률 격차는 single-turn 평가에서보다 크게 벌어졌다 (1.30점). Self-host LoRA 모델이 멀티턴 조건에서 약점을 노출한 본 결과는 라이브 봇 운영 구조 결정의 직접 근거가 됐으며, 데비&마를렌은 현재 single-turn 키워드 트리거로 의도적 한정 운영 중이다. (a) 모델별 평균 정답률(1-5) — GPT-5.4 mini 2.60로 최상, Gemma4+LoRA 1.30로 최하. (b) 이전 대화 history를 명시적으로 참조한 비율(%) — 상용 small 모델일수록 활용률이 높다.

결론 — 본 평가가 양건호의 운영 결정에 어떻게 반영됐는가

■ 본 보고서가 발견한 사실

1. RAG 효과: closed-book 평균 1.81 → open-book 4.63 (+2.82점)
2. Haiku 4.5 closed-book 할루시네이션율 32% (4 모델 중 가장 낮음, 정직)
3. Haiku 4.5 + RAG context = correctness 4.73 / 5 (운영 안전선 도달)
4. Multi-turn 평가 — Gemma4 + LoRA 가 4 모델 중 최저 (페르소나 fine-tune 의 trade-off)
5. Maple closed (부분 학습 도메인) hall% 는 ER closed 보다 모든 모델에서 ↑

■ 위 결과를 바탕으로 한 양건호의 운영 의사결정

- 라이브 봇 데비&마를렌(158서버) 모델: Claude Haiku 4.5 채용
사유: closed-book 정직성 0% hall + RAG 결합 시 안전선 + 비용/지연 균형
- Custom tool RAG 도입: search_patchnote (ER 공식 사이트 패치노트 fetch + 섹션 파싱)
사유: closed→open +3점 효과를 봇 응답 품질에 직접 반영
- 봇 대화 구조: single-turn 키워드 트리거로 의도적 한정
사유: multi-turn 에서 LoRA 모델이 약하다는 본 보고서 결과 (1.30 vs 2.60)
→ 무리하게 multi-turn 대화 봇으로 키우지 않음
- Portfolio 챗봇(geno-portfolio): Sonnet 4.6 + search_portfolio custom tool
사유: 시연 트래픽(저빈도) 에선 premium 으로 임팩트 우선 — 같은 framework, 다른 tier

■ NEXON LLM 평가 어시스턴트 인턴 지원자로서

본 보고서는 단순 모델 비교가 아니라

'평가 → 결론 → 본인이 운영 중인 시스템에 적용' 의 close loop 을 보여주는 사례입니다.

같은 framework 를 새로운 NEXON 도메인 (메이플/카트/던파 등)에 그대로 확장 가능합니다.